



Facultatea de
Matematică și Informatică

Universitatea din București

ELIMINAREA ZGOMOTULUI SI RESTITUIREA IMAGINII ÎN PROCESAREA IMAGINILOR DIGITALE

Ianuarie 2024

Autori:

Victor David
Laurențiu-Vasile Crețu
Robert-Alexandru Sorete
Nicoleta-Anastasia Dinoiu

Cuprins

1	Introducere	2
1.1	Contextul și Importanța Eliminării Zgomotului din Imagini	2
1.2	Istoric	2
2	Zgomotul imaginilor digitale	4
2.1	Conceptul de reducere al zgomotului	4
2.2	Zgomotul Aditiv și Multiplicativ	4
2.3	Zgomotul Gaussian	5
2.4	Zgomotul Speckle	5
2.5	Zgomotul Impulsiv	6
2.6	Analiza Histogramelor pentru Diverse Tipuri de Zgomot	7
3	Algoritmi de reducere a zgomotului din imagini	8
3.1	Filtrarea Spațială	8
3.1.1	Filtre Liniare	8
3.1.2	Filtre Non-Liniare	10
3.1.3	Comparație între Filtrul de Medie și Filtrul Median asupra diferitelor tipuri de zgomote	10
3.2	Filtrarea prin Transformarea Domeniului	13
3.2.1	Filtrarea în Domeniul Frecvenței	13
3.2.2	Filtrarea în Domeniul Wavelet	15
4	Restituirea imaginilor	17
4.1	Deconvoluția Wiener	17
4.2	Filtrul CLS	19
5	Recuperarea imaginilor îmbătrânite folsind Rețele Neurop- nale	22
6	Concluzie	25

1 Introducere

Într-o lume din ce în ce mai digitală, imaginile digitale joacă un rol important în aplicațiile de zi cu zi, cum ar fi camerele digitale, imagistica prin rezonanță magnetică, televiziunea prin satelit, precum și în domeniile de cercetare și tehnologie, cum ar fi sistemul de informații geografice. În general, seturile de date colectate de senzorii de imagine sunt contaminate de zgomot.

Instrumente imperfecte, probleme cu procesul de achiziție a datelor, fenomenele naturale care interferează, toate acestea pot corupe datele de interes. Din acest motiv, reducerea zgomotului devine o etapă fundamentală în procesul de analiză a imaginilor, marcând primul pas ce trebuie efectuat înainte de analiza concisă a imaginilor.

Zgomotul poate fi adăugat și în procesul de îmbătrânire a imaginilor, manifestându-se prin fenomenele de îngălbenire sau crăpare a imaginilor, cât și prin erori de capturare a imaginii manifestate prin motion blur. Astfel, metodele de eliminare a zgomotului sunt necesare pentru a preveni aceste tipuri de corupție din imaginile digitale.

În această lucrare sunt expuse principalele metode de reducere a zgomotului în imagini, dar și implementarea unor algoritmi destinați recuperării și recondiționării imaginilor în urma fenomenelor de motion blur și de îmbătrânire a imaginilor.

1.1 Contextul și Importanța Eliminării Zgomotului din Imagini

Una dintre provocările fundamentale în domeniul procesării imaginilor și vizuierii calculatoarelor este reprezentată de eliminarea zgomotului din imagini, unde obiectivul principal este de a estima imaginea originală prin suprimatea zgomotului dintr-o versiune a acesteia contaminată de zgomot. Eliminarea zgomotului joacă un rol important într-o gamă largă de aplicații, cum ar fi restaurarea imaginilor, segmentarea imaginilor și clasificarea imaginilor, unde obținerea conținutului original al imaginii este crucială.

Scopul este de a diminua zgomotul în imagini naturale, minimizând pierderea caracteristicilor originale și îmbunătățind raportul semnal-zgomot (SNR). Principalele provocări pentru reducerea zgomotului în imagini sunt următoarele: zonele plate ar trebui să fie netede, marginile ar trebui protejate fără a fi estompate, texturile ar trebui să fie păstrate, iar noi artefacte nu ar trebui să fie generate.

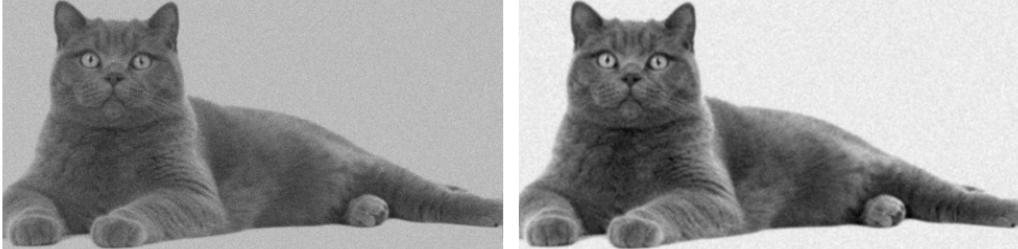


Figura 1: Exemplu de înlăturare a zgomotului cu filtrul Wiener

1.2 Istorici

Eliminarea zgomotului din imagini are o istorie bogată, începând cu dezvoltarea teoriei filtrării Wiener-Kolmogorov în anii 1940. Această teorie a pus bazele proiectării filtrelor pentru procesele gaussiene staționare. De-a lungul deceniilor, au fost aduse contribuții semnificative de către Peter Swerling, Rulian Stratonovich și Rudolf Kalman, conducând la aplicații în radar, sateliți și filtrare adaptivă.

În anii 1970, atenția s-a îndreptat către semnale bidimensionale precum imagini digitale. Suprimarea zgomotului din imagini a fost explorată inițial de Nasser Nahi și Ali Habibi, în timp ce filtrarea Kalman a fost extinsă la 2D. Cu toate acestea, limitările practice au împiedicat utilizarea pe scară largă până în anii 1980, până când s-a ajuns la un avans tehnologic necesar. Lucrarea lui Jong-Sen Lee din anii 1980 a implementat filtrarea Kalman 2D pentru îmbunătățirea imaginilor/filtrarea zgomotului, deschizând calea pentru aplicații în inginerie. La sfârșitul anilor 1980 a apărut teoria undinelor (Wavelet Transform), ce a devenit o unealtă populară pentru sarcini de procesare a imaginilor, între anii 1990 și începutul anilor 2000 având loc o creștere a algoritmilor de eliminare a zgomotului bazați pe wavelets.

2 Zgomotul imaginilor digitale

Zgomotul în imagini digitale reprezintă variațiile nedorite ale intensității pixelilor care sunt introduse în imagine în timpul procesului de capturare, stocare sau transmitere a acesteia. Aceste variații pot fi cauzate de factori precum perturbările în procesul de capturare a imaginii, interferențe electro-magnetice, erori de senzori, sau alte influențe externe și interne care conduc la modificări ale intensității pixelilor în mod aleator sau periodic.

2.1 Conceptul de reducere al zgomotului

Reducerea zgomotului din imagini îmbunătățește calitatea imaginilor printr-o serie de operații, în timp ce încearcă să păstreze informațiile originale și să îndepărteze informațiile redundante din semnal. Într-o aplicație practică este crucială studierea acestui algoritm, deoarece în procesarea de imagini medicale, orice eroare minimă poate afecta diagnoza unui doctor sau poate pune viața unui pacient în pericol.

2.2 Zgomotul Aditiv și Multiplicativ

Zgomotul aditiv este reprezentat în felul următor:

$$w(x, y) = s(x, y) + n(x, y), \quad (1)$$

unde $s(x, y)$ este imaginea originală și $n(x, y)$ denotă zgomotul introdus pentru a produce imaginea coruptă $w(x, y)$ la locația pixelului (x, y) . Câteva exemple de zgomot aditiv sunt: zgomotul Gaussian, Uniform, Poisson, Impulsiv (Sare și Piper).

Zgomotul multiplicativ poate fi definit de următoarea formulă:

$$W(x, y) = s(x, y) * n(x, y), \quad (2)$$

unde $s(x, y)$ și $n(x, y)$ sunt aceleasi ca mai sus. Unele dintre cele mai cunoscute tipuri de zgomote multiplicative sunt zgomotul Speckle și cel Exponențial.

2.3 Zgomotul Gaussian

Zgomotul Gaussian este uniform distribuit asupra semnalului. Acest lucru înseamnă că fiecare pixel din imagine este suma dintre valoarea reală a pixelului și a unei valori aleatoare de zgomot a distribuției Gaussiene. Așa cum indică și numele, acest tip de zgomot urmează o distribuție Gaussiană.

$$F(g) = \frac{\frac{1}{\sqrt{2\pi\sigma^2}}e^{-(g-m)^2}}{2\sigma^2}, \quad (3)$$

unde g reprezintă nivelul de gri, m este media sau valoarea medie a funcției, iar c este deviația standard a zgomotului. În mod grafic, este reprezentat ca o curbă sub forma unui clopot:

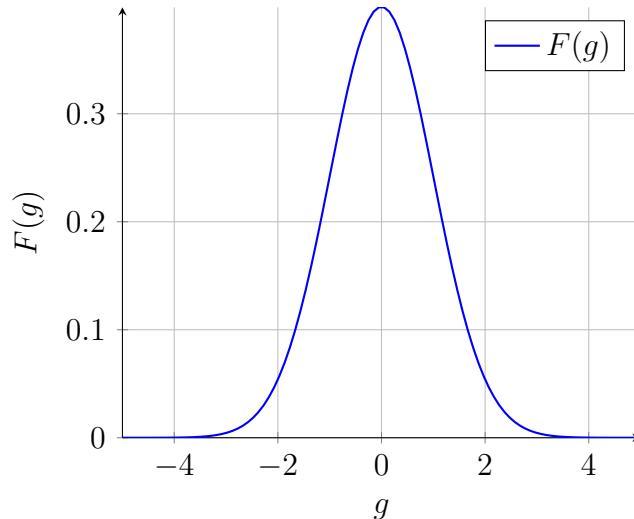


Figura 2: Distribuția Gaussiana

2.4 Zgomotul Speckle

Zgomotul Speckle este considerat ca fiind un zgomot multiplicativ. Acesta este un zgomot granular care degradează calitatea imaginilor obținute de sistemele de imagistică coerentă, cum ar fi lasere, radarele active sau sisteme radar cu diafragmă sintetică (SAR).

Din cauza fluctuațiilor aleatorii în semnalul de întoarcere al radarului,

apare zgomotul de tip speckle, ce poate fi observat prin nivelul crescut de gri al imaginii. Zgomotul Speckle îngreunează interpretarea imaginilor SAR cauzate în principal de procesarea coerentă a semnalelor retrodifuzate (backscatter) de la mai multe ținte distribuite.

Zgomotul de tip speckle urmează o distribuție gamma, care este caracterizată de funcția de densitate de probabilitate:

$$F(g) = \frac{g^{\alpha-1}}{(\alpha-1)!\alpha^\alpha} e^{-\frac{g}{\alpha}}, \quad (4)$$

unde varianța este σ^2 și g reprezintă nivelul de gri.

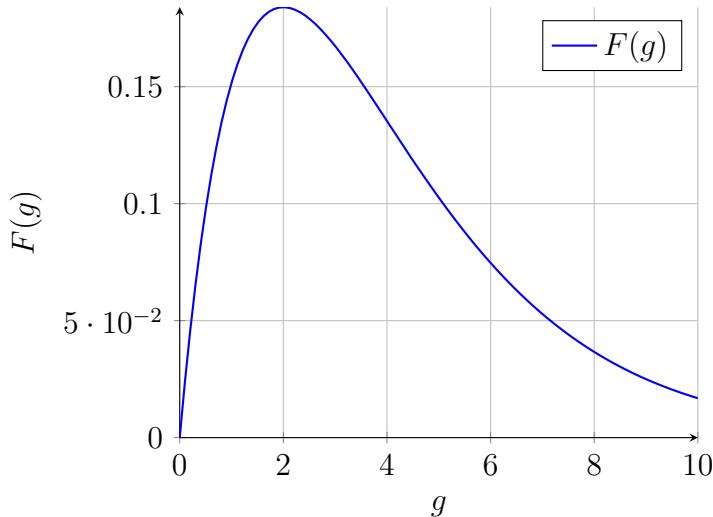
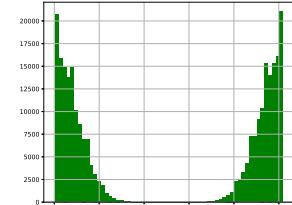


Figura 3: Distribuția Gamma

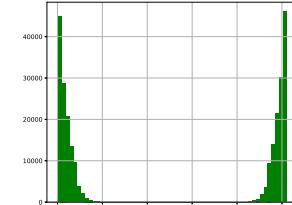
2.5 Zgomotul Impulsiv

Zgomotul Impulsiv este adesea numit sare-și-piper sau zgomot de impulsuri. O imagine ce conține acest tip de zgomot va avea pixeli închisi in zonele deschise si pixeli deschiși la culoare in regiunile întunecate. Poate fi cauzat de pixeli morți, erori de conversie sau erori de transmisie a datelor.

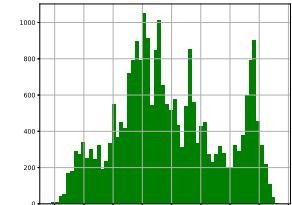
2.6 Analiza Histogramelor pentru Diverse Tipuri de Zgomot



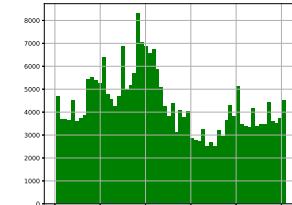
(a) Zgomot Gaussian



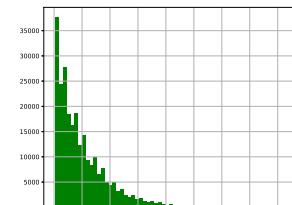
(b) Zgomot Poisson



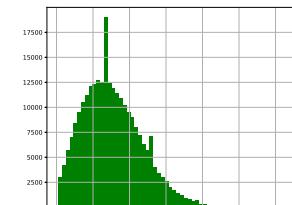
(c) Zgomot Impulsiv



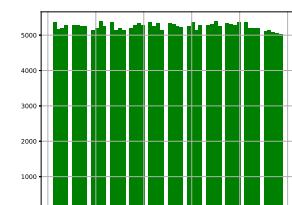
(d) Zgomot Speckle



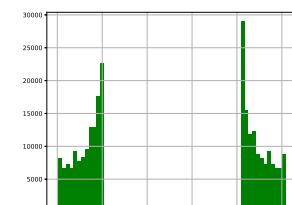
(e) Zgomot Exponential



(f) Zgomot Rayleigh



(g) Zgomot Uniform



(h) Zgomot Periodic

3 Algoritmi de reducere a zgomotului din imagini

În prezent, se disting două categorii de algoritmi pentru reducerea zgomotului în imagini: Filtrarea Spațială și Filtrarea prin Transformarea Domeniului.

3.1 Filtrarea Spațială

Filtrarea spațială reprezintă o opțiune eficientă în cazul în care se întâlnește exclusiv zgomot aditiv. Aceasta poate fi ulterior împărțită în două categorii distincte: Filtre Liniare și Filtre Non-Liniare.

3.1.1 Filtre Liniare

Filtrul de Medie

Ideea principală a acestui filtru constă pur și simplu în înlocuirea valorii fiecarui pixel dintr-o imagine cu valoarea medie a pixelilor adiacenți. Filtrul funcționează pe baza algoritmului „ferestre glisante”, unde fereastra este reprezentată de un kernel de dimensiune $N \times N$ (cu N impar). Fereastra se deplasează pixel cu pixel pe întreaga imagine, calculând media pentru regiunea respectivă.

Avantajele acestui filtru sunt implementarea ușoară și eficiența asupra zgomotului gaussian. Principalul dezavantaj al acestui filtru este faptul că estompează detaliile din imagine și că nu este eficient în tratarea altor tipuri de zgomot, precum zgomotul impulsiv.



Figura 5: Imaginea originală vs Imaginea filtrată

Prima imagine din Figura 5 a fost realizată prin adăugarea de zgomot Gaussian ($\sigma = 25$), iar a doua imagine a fost obținută prin aplicarea Filtru-lui de Medie, cu o dimensiunea a kernelului $k = 5$.

Filtrul Wiener

Filtrul Wiener este un filtru ce adoptă o abordare statistică pentru a elibera zgomotul dintr-un semnal corupt. Ceea ce îl deosebește este abordarea sa statistică și capacitatea de a obține un răspuns dorit al frecvenței. În loc să se concentreze doar pe reducerea zgomotului, Filtrul Wiener ia în considerare proprietăți spectrale ale semnalului original și ale zgomotului.

Pentru a efectua operația de filtrare, este esențial să se cunoască proprietățile spectrale ale semnalului original și ale zgomotului asociat. Filtrul Wiener își propune să obțină un filtru LTI (Linear Time-Invariant) care să furnizeze o ieșire cât mai apropiată de semnalul original.

Obiectivul filtrului Wiener este să minimizeze MSE, adică să reducă discrepanța pătratică medie dintre semnalul filtrat și semnalul original. Astfel, proiectarea algoritmului constă în alegerea parametrilor care minimizează MSE pentru a obține o reconstrucție cât mai precisă a semnalului.

În acest algoritm, un pixel y din imaginea filtrată este derivat dintr-un pixel x din imaginea de intrare cu zgomot prin următoarea transformare:

$$y = \mu_x + (x - \mu_x) \frac{v_x}{v_x + v_n}, \quad (5)$$

unde μ_x și v_x reprezintă media și varianța lui x într-o vecinătate din jurul pixelului, iar v_n este varianța zgomotului aditiv, estimată din imaginea de intrare. Fiecare pixel de ieșire este suma mediei locale dintr-o vecinătate a pixelului de intrare și a unui termen local de contrast $(x - \mu_x)$ care este scalat astfel încât în regiunile cu detalii ridicate, unde varianța zgomotului (v_n) este mult mai mică decât varianța imaginii (v_x), factorul de scalare este foarte aproape de 1 și pixelul de ieșire y este foarte aproape de pixelul de intrare x cu puțin filtru, dar în regiunile cu detalii scăzute, unde varianța imaginii este mai mică, pixelul de ieșire tinde să semene mai mult cu media locală (adică este filtrat trece-jos).

Vom discuta despre acest filtru mai târziu în această lucrare, unde vom aborda o implementare diferită față de cea spațială.

3.1.2 Filtre Non-Liniare

Filtrul Median

Se bazează pe aceeași idee ca și filtrul de medie, cu excepția faptului că în loc să se utilizeze media aritmetică, se aplică funcția mediană care înlocuiește fiecare pixel cu valoarea mediană din fereastra respectivă.

Filtrul median se dovedește a fi mai robust în fața valorilor extreme comparativ cu filtrul de medie, astfel că este capabil să elimine aceste valori aberante fără a diminua claritatea imaginii.

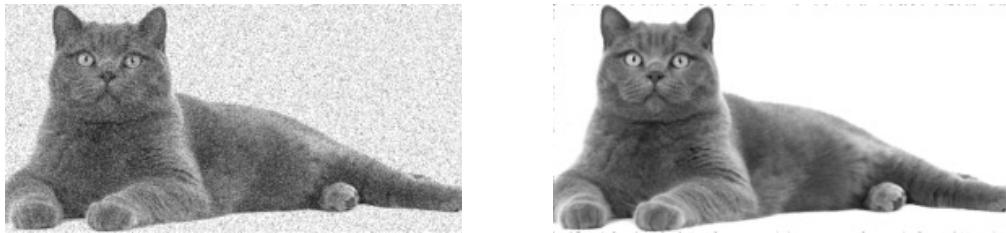


Figura 6: Imaginea originală vs Imaginea filtrată

Prima imagine din Figura 6 a fost realizată prin adăugarea de zgomot Impulsiv, iar a doua imagine a fost obținută prin aplicarea Filtrului Median, cu o dimensiunea a kernelului $k = 5$.

3.1.3 Comparație între Filtrul de Medie și Filtrul Median asupra diferitelor tipuri de zgomote

În această secțiune, realizăm o comparație între Filtrul de Medie și Filtrul Median aplicate diferitelor tipuri de zgomote. Pentru evaluarea performanței, am utilizat raportul PSNR (Peak Signal-to-Noise Ratio). PSNR cuantifică calitatea unei imagini în comparație cu imaginea originală și este calculat pe baza raportului dintre maximul valorii pătratice a semnalului și eroarea medie pătratică.

Fiecare rând al comparației de mai jos conține trei coloane:

1. **Imaginea cu Zgomot:** Prima coloană prezintă imaginea originală cu aplicarea tipului specific de zgomot.

2. **Imaginea Obținută prin aplicarea Filtrului de Medie:** A doua coloană conține imaginea rezultată după aplicarea Filtrului de Medie asupra imaginii cu zgomot.
3. **Imaginea Obținută prin aplicarea Filtrului Median:** A treia coloană prezintă imaginea rezultată după aplicarea Filtrului Median asupra imaginii cu zgomot.



Figura 7: Zgomot Gaussian



Figura 8: Zgomot Poisson



Figura 9: Zgomot Impulsiv



Figura 10: Zgomot Speckle



Figura 11: Zgomot Exponential



Figura 12: Zgomot Rayleigh



Figura 13: Zgomot Uniform



Figura 14: Zgomot Periodic

Tip de zgomot	PSNR imaginea cu zgomot	PSNR imaginea cu Filtru de Medie	PSNR imaginea cu Filtru Median
Gaussian	21.44	23.76	26.16
Poisson	27.36	24.66	26.98
Impulsiv	14.23	22.25	27.02
Speckle	7.35	12.09	15.49
Exponential	20.65	21.38	22.87
Rayleigh	20.44	20.07	20.61
Uniform	22.19	21.38	21.89
Periodic	18.41	17.60	17.90

Tabela 1: Valorile PSNR pentru diferite tipuri de zgomote și Filtru de Medie și Median

3.2 Filtrarea prin Transformarea Domeniului

Filtrarea prin transformarea domeniului reprezintă o tehnică de prelucrare a semnalelor, în care datele sunt transformate din domeniul spațial în alt domeniu matematic (domeniul frecvenței sau al undelor) pentru a eficientiza operațiile de filtrare, cum ar fi convolução. Această transformare permite utilizarea optimă a tehniciilor de filtrare, iar rezultatul poate fi convertit înapoi în domeniul original, fără să existe informații pierdute.

3.2.1 Filtrarea în Domeniul Frecvenței

Se referă la utilizarea filtrelor trece-jos folosind Transformata Fourier. Zgomotul este eliminat prin stabilirea unui prag de frecvență și aplicarea

acestuia asupra imaginii în domeniul frecvenței, unde componenta zgomotului este decorelată de semnalul util.

Principalul dezavantaj al Transformatei Fourier Rapide constă în faptul că informațiile marginale sunt distribuite pe întregul spectru al frecvenței, și nu pot fi localizate în timp sau spațiu. Prin urmare, filtrul trece-jos afectează imaginea prin estomparea marginilor (muchiilor). Aici apare conceptul de localizare a semnalului în timp și frecvență folosind Transformata Wavelet, ce oferă o metodă deosebit de utilă pentru reducerea zgomotului în imagini atunci când păstrarea muchiilor este importantă.

Am aplicat procesul de filtrare în domeniul frecvenței pentru a elimina zgomotul din imaginea cu pisica british fold folosită și în capitolele anterioare. În prima etapă a acestui proces am adăugat zgomot Gaussian imaginii originale, după care am aplicat Transformata Fourier 2D asupra imaginii cu zgomot, transpunând astfel imaginea din domeniul spațial în cel al frecvenței.

La pasul al doilea am proiectat un Filtru Trece-Jos și l-am aplicat asupra imaginii zgomotoase, având ca scop eliminarea componentelor de frecvență înaltă, ce corespund zgomotului din imagine.



Figura 15: Filtru trece-jos

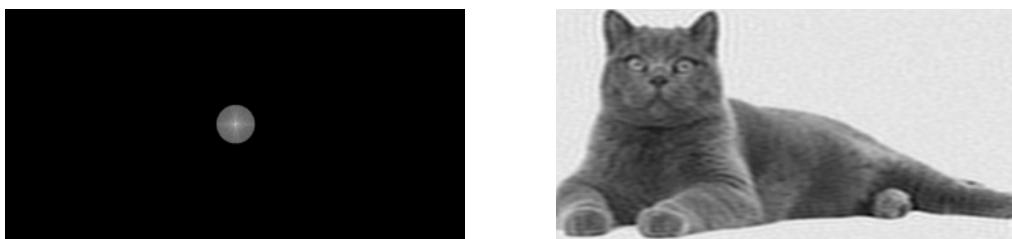


Figura 16: Transformata Fourier inversă

În ultima etapă a acestui proces am aplicat Transformata Fourier Inversă pentru a obține imaginea fără zgomot, revenindu-se astfel din domeniul frecvenței în cel spațial.



(a) Imaginea cu zgomot



(b) Imaginea filtrată

3.2.2 Filtrarea în Domeniul Wavelet

Operarea în domeniul Wavelet este preferată deoarece Transformata Wavelet Discretă concentrează energia semnalului într-un număr mic de coeficienți, prin urmare, utilizarea DWT asupra imaginii zgomoase rezultă un număr mic de coeficienți ce au un raport semnal/zgomot (SNR) ridicat, în timp ce un număr relativ mare de coeficienți au un SNR scăzut. După eliminarea coeficienților cu SNR scăzut, imaginea este reconstruită cu ajutorul IDWT (Inversa Transformării Wavelet Discrete), ce rezultă eliminarea sau filtrarea zgomotului. Metodele Wavelet au un avantaj semnificativ, acela de a localiza simultan timpul cu frecvența, fiind astfel o alegere potrivită pentru reducerea zgomotului din imagine.

Aplicăm procesul de eliminare a zgomotului folosind Transformata Wavelet pe imaginea pisica british cu zgomotul Gaussian. În prima etapă, imaginea este descompusă într-o serie de coeficienți wavelet de tip „haar”, care reprezintă detaliile și aproximările la diferite niveluri de scală. Nivelul de descompunere indică de câte ori este aplicată transformata wavelet asupra imaginii.

După obținerea coeficienților, stabilim un prag care acționează ca limită pentru coeficienții mici, considerați a fi asociați zgomotului. Cu ajutorul acestui prag, aplicăm o tehnică de umplere numită „soft thresholding” asupra coeficienților. Cu alte cuvinte, coeficienții cu valorile sub prag sunt reduși sau eliminați, având ca impact reducerea zgomotului.

În final, imaginea este reconstruită utilizând inversa Transformatei Discrete Wavelet. Acest proces permite păstrarea detaliilor, eliminând în același timp componentele zgomot.



Figura 18: Wavelet haar, level=1



Figura 19: Wavelet haar, level=2



Figura 20: Wavelet haar, level=3

4 Restituirea imaginilor

4.1 Deconvoluția Wiener

Filtrul Wiener a fost unul dintre primele metode dezvoltate pentru reducerea zgomotului aditiv aleator în imagini. Aceasta funcționează pe premisa că zgomotul aditiv este un proces aleatoriu staționar, independent de locația pixelului; algoritmul minimizează eroarea dintre imaginea originală și cea reconstruită. Filtrul Wiener este un filtru trece-jos, dar în loc să aibă o singură frecvență de tăiere, este un filtru variabil în spațiu, proiectat să folosească o tăiere redusă în regiunile cu detalii scăzute și o tăiere mare pentru a păstra detaliile în regiunile cu margini sau alte caracteristici cu variație mare. Dimensiunea ferestrei determină tăierea frecvenței generale: ferestrele mai mari corespund unor frecvențe de tăiere mai scăzute și, prin urmare, mai multă estompare și reducere a zgomotului.

Având o imagine x și un kernel de convoluție invariant la deplasare sau o funcție de răspândire a punctelor (PSF) c , se formează o imagine 2D b conform următoarei relații:

$$b = cx + \eta, \quad (6)$$

Aici, măsurările sunt afectate de un termen de zgomot aditiv, independent de semnal η . Teorema de convoluție afirmă că ecuația 6 poate fi scrisă similar ca o înmulțire în domeniul Fourier:

$$b = \mathcal{F}^{-1}\{\mathcal{F}\{c\} \cdot \mathcal{F}\{x\}\}, \quad (7)$$

unde \cdot reprezintă produsul element cu element. Se observă că Ecuțiile 6 și 7 sunt echivalente numeric doar atunci când convoluția este efectuată cu condiții de limită circulare.

Deconvoluția este problema de a găsi o estimare \tilde{x} a imaginii latente b din măsurători neclare, cu zgomot.

Principala problemă a filtrării inverse este că zgomotul de măsurare este ignorat pentru reconstrucție. Filtrul Wiener aplicat problemei de deconvoluție adaugă un factor de amortizare la filtrul invers:

$$\tilde{x} = \mathcal{F}^{-1}\left\{ \frac{|\mathcal{F}\{c\}|^2}{|\mathcal{F}\{c\}|^2 + \frac{1}{\text{SNR}}} \cdot \frac{\mathcal{F}\{b\}}{\mathcal{F}\{c\}} \right\}, \quad (8)$$

unde SNR reprezintă raportul semnal-zgomot. Dacă nu există zgomot în măsurători, SNR-ul este infinit de mare. În această situație particulară,

filtrarea Wiener este echivalentă cu filtrarea inversă. În toate celelalte cazuri, Ecuatia 8 adaugă un factor de amortizare pe frecvență care necesită cunoașterea magnitudinii semnalului și a densității spectrale de putere a zgomotului pentru fiecare frecvență. O aproximare comună pentru aceasta este de a alege termenul de semnal ca intensitate medie a imaginii și termenul de zgomet ca deviația standard a distribuției de zgomet η .

Am selectat imaginea din Figura 21 ca imagine de test, iar Figura 22 a fost generată prin adăugarea de zgomet. Procesul a implicat adăugarea a 30% din deviația standard a imaginii originale la fiecare pixel al imaginii convoluționate. Această adiție a fost efectuată înmulțind valorile rezultate cu numere aleatoare generate dintr-o distribuție normală standard. În continuare, Figura 23 a fost obținută prin aplicarea filtrului Wiener. Observăm că, deși zgometul a fost redus semnificativ în imaginea filtrată, raportul PSNR (Peak Signal-to-Noise Ratio) a înregistrat o scădere. Este important de menționat că, în cazul Figurii 4a, deși filtrul Wiener a îmbunătățit vizibil claritatea imaginii, PSNR a înregistrat o scădere, sugerând că raportul dintre semnal și zgomet nu este atât de favorabil.

Fiecare imagine din figurile de mai jos are atașat spectrul de frecvență, ce evidențiază intensitatea frecvențelor din imagine. Spectrul de frecvență a fost obținut prin aplicarea unei transformate Fourier bidimensionale. După cum se observă din graficul spectrului de frecvență a imaginii filtrate prezența frecvențelor înalte indică faptul că filtrul Wiener a reușit să atenueze efectele negative ale zgometului, menținând totuși detaliile din imaginea inițială graficul spectrului.

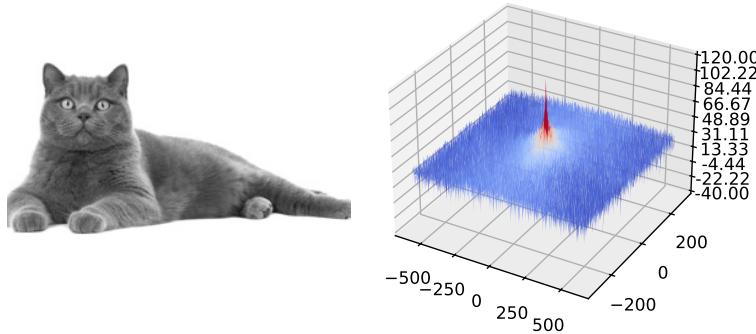


Figura 21: Imaginea originală

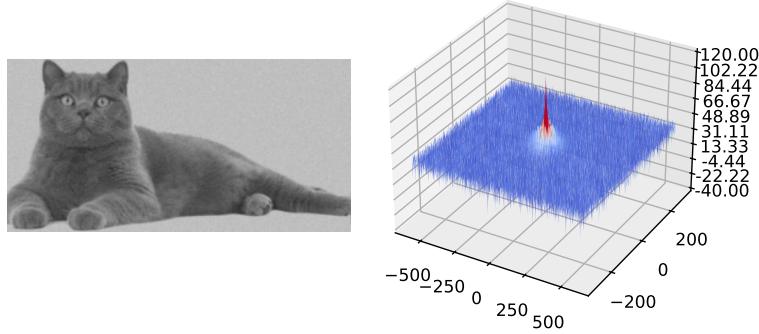


Figura 22: Imaginea cu zgomot

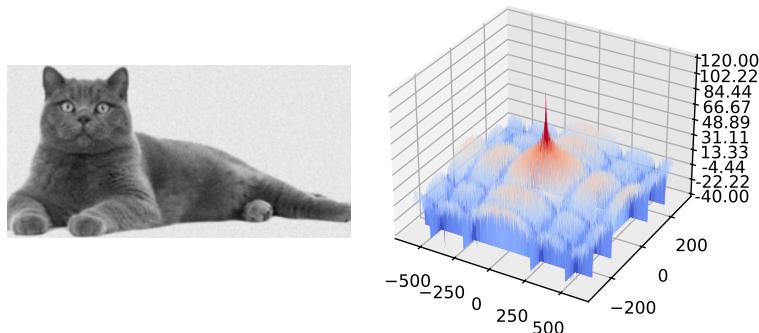


Figura 23: Imaginea filtrată

4.2 Filtrul CLS

Filtrul CLS (Constrained Least Squares) încearcă să obțină un compromis între accentuarea imaginii și îmbunătățirea zgomotului aleator prin maximizarea netezimii imaginii restaurate, respectând în același timp o constrângere la cât de bine (în sensul diferențelor medii pătratice) imaginea restaurată se potrivește cu imaginea digitală. Frecvența de răspuns a filtrului CLS bazat pe modelul d/d este dată de formula:

$$\hat{f}[v_1, v_2] = \frac{\hat{h}^*[v_1, v_2]}{|\hat{h}[v_1, v_2]|^2 + \alpha |\hat{c}[v_1, v_2]|^2} \quad (9)$$

unde $\hat{c}[v_1, v_2]$ este un vector de filtrare trece-sus specificat de utilizator, periodic cu perioadele $N_1 \times N_2$, iar α este un parametru non-negativ. În literatura de specialitate, c este numit parametru de stabilizare, iar α este cunoscut ca parametrul de netezire. O alegere frecvență pentru parametrul de stabilizare este vectorul de filtrare trece-sus:

$$\hat{c}[v_1, v_2] = 2(1 - \cos(2\pi\omega)) \quad (10)$$

Frecvența ω este definită ca fiind $\omega = \sqrt{\left(\frac{v'_1}{N_1}\right)^2 + \left(\frac{v'_2}{N_2}\right)^2}$ unde $v'_1 = |v_1| \bmod N_1$ și $v'_2 = |v_2| \bmod N_2$ fac vectorul c periodic cu perioada $N_1 \times N_2$. Parametrul de netezire α este determinat direct din imaginea digitală.

La frecvențe joase, unde zgometul aleator este de obicei neglijabil în comparație cu scena, $\alpha|\hat{c}[v_1, v_2]|^2$ este mic în raport cu $|\hat{h}[v_1, v_2]|^2$; acest lucru permite filtrului CLS să amplifice frecvențele joase. La frecvențe mari, unde zgometul aleator este în general cel mai semnificativ, $\alpha|\hat{c}[v_1, v_2]|^2$ este cel mai mare în raport cu $|\hat{h}[v_1, v_2]|^2$; acest lucru previne filtrul CLS să amplifice frecvențele înalte, reducând astfel îmbunătățirea zgometului aleator. În cazul special în care nu există zgomet aditiv aleator, $\alpha = 0$ și filtrul CLS se reduce la filtrul invers.

Am aplicat filtrul CLS aceleași imagini ca în exemplul Wiener. De această dată, imaginea din Figura 25 a fost obținută prin aplicarea unui filtru de blur și zgomet aleatoriu asupra imaginii inițiale, în timp ce imaginea din Figura 26 a fost obținută prin aplicarea filtrului CLS. O reducere semnificativă a zgometului în imaginea rezultată după aplicarea filtrului CLS, în comparație cu imaginea afectată de zgomet și blur, iar raportul PSNR este mai ridicat în comparație cu filtrul Wiener.

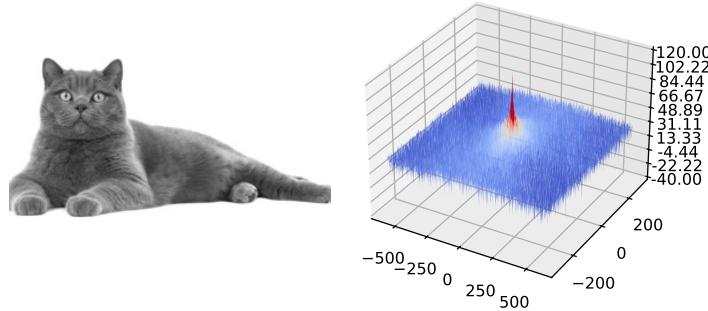


Figura 24: Imaginea originală

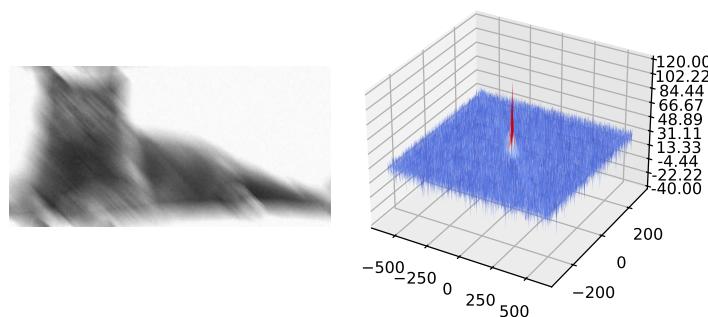


Figura 25: Imaginea cu zgomot

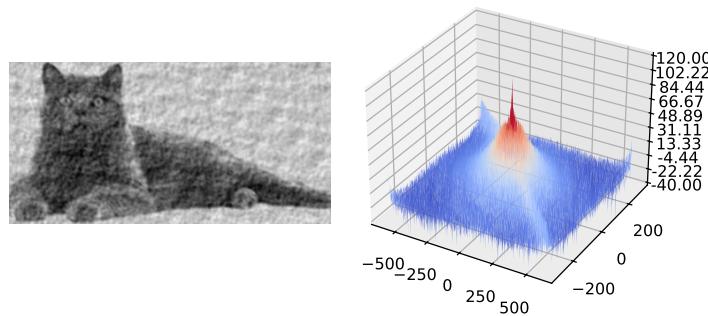
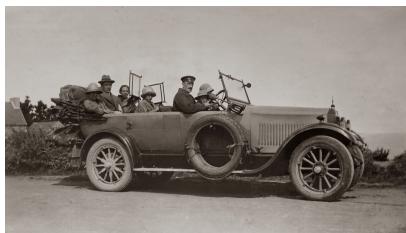


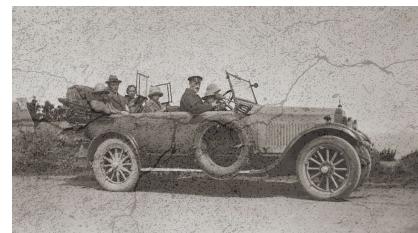
Figura 26: Imaginea filtrată

5 Recuperarea imaginilor îmbătrânite folosind Rețele Neuronale

În acest capitol am încercat să realizăm un procedeu de reconstrucție a imaginilor îmbătrânite prin eliminarea crăpăturilor folosind o Rețea Neuronală. Acest proces a implicat prima etapă a antrenării rețelei, în care am colectat un set de 211 imagini vechi, asupra căroro am aplicat un efect vectorial de crăpături. Astfel, în setul de date de antrenare sunt 422 de imagini, câte o imagine veche și corespondentă ei căreia i s-a aplicat efectul de crăpături.



(a) Imaginea 1 inițială



(b) Imaginea 1 procesată



(a) Imaginea 2 inițială



(b) Imaginea 2 procesată

Arhitectura rețelei neuronale pe care am folosit-o este una destul de simplă, cu 2 straturi de convecție și funcții de activare ReLU între ele. Scopul acestei rețele este să învețe să elimine crăpăturile din imagini, prin observarea diferențelor dintre imaginea de plecare, cu crăpături, și imaginea dorită finală, fără crăpături. În figurile de mai jos se pot observa câteva rezultate ale acestui model:



(a) Imaginea de test



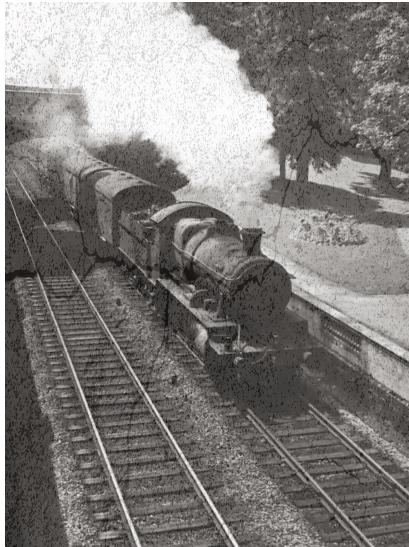
(b) Imaginea rezultată



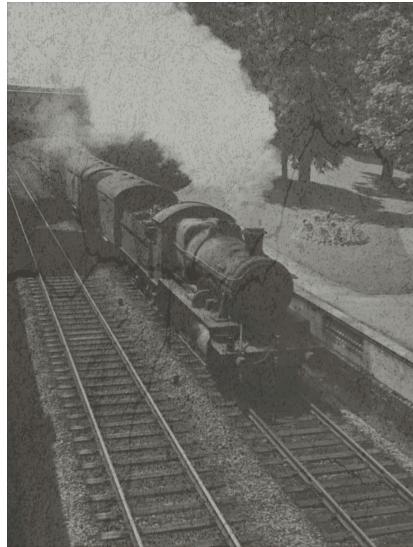
(a) Imaginea de test



(b) Imaginea rezultată



(a) Imaginea de test



(b) Imaginea rezultată

6 Concluzie

Scopul acestei lucrări este de a prezenta tehniciile clasice de eliminare a zgomotului și de reconstrucție a imaginilor. Deoarece imaginile au ajuns importante în multe industrii, reducerea zgomotului reprezintă o sarcină importantă de preprocesare. În această lucrare, sunt expuse diferite tipuri de zgomot care pot compromite imaginea și diferite tipuri de filtre care sunt utilizate pentru a îmbunătăți imaginea.

Studii avansate asupra tehniciilor de suprimare a zgomotului dovedesc că filtrele Wavelet sunt mai performante decât filtre din spectrul frecvenței sau alte filtre spațiale. Filtrele spațiale funcționează prin netezirea unei ferestre fixe ce poate produce artefacte în jurul obiectelor sau pot provoca netezire (blurare) excesivă. De asemenea, în ultima parte a lucrării, sunt prezentate câteva strategii de reconstrucție a imaginilor afectate de fenomene precum motion blur sau crăpare a imaginilor îmbătrâname. Acești algoritmi au demonstrat capacitatea de a restitui detaliile pierdute și de a îmbunătăți calitatea generală a imaginilor.

Bibliografie

- [1] Bahadir, K. G. și Xin L. (2013) *Image Restoration: Fundamentals and Advances*. California: CRC Press.
- [2] Fan, L., Zhang, F., Fan, H. și Zhang, C. (2019) 'Brief review of image denoising techniques', *Visual Computing for Industry, Biomedicine, and Art*. 2, articol 7.
- [3] GeeksforGeeks (2021) *Implement Deep Autoencoder in PyTorch for Image Reconstruction*. Valabil la: <https://geeksforgeeks.org/implement-deep-autoencoder-in-pytorch-for-image-reconstruction/> (Accesat: 31 Ianuarie 2024)
- [4] Gupta, B. and Negi, S.S. (2013) 'Image Denoising with Linear and Non-Linear Filters: A REVIEW', *International Journal of Computer Science Issues*, 10(6), articol 2.
- [5] Hazra, R. (1995) *Constrained least-squares digital image restoration*. PhD thesis. Colegiul William & Mary. Valabil la: <https://doi.org/10.21220/s2-vrc2-fx80>
- [6] Pexels (fără dată) *Old photo*. Valabil la: <https://www.pexels.com/search/old%20photo/> (Accesat: 31 Ianuarie 2024)
- [7] PTC (2023) *Wiener Filtering*. Valabil la: https://support.ptc.com/help/mathcad/r9.0/en/index.html#page/PTC_Mathcad_Help/wiener_filtering.html (Accesat: 26 Ianuarie 2024)
- [8] Sandipan, D. (2020) *Python Image Processing Cookbook*. Birmingham: Packt Publishing.
- [9] Wetzstein, G. (2018) 'Image Deconvolution'. *EE367/CS448I Computational Imaging and Display*. Universitatea Stanford. Valabil la https://stanford.edu/class/ee367/reading/lecture6_notes.pdf (Accesat: 30 Ianuarie 2024)
- [10] Wu, C. și Gao, T. (2021) 'Image Denoise Methods Based on Deep Learning', *Journal of Physics: Conference Series*. 1883(1), articol 012112.